MVP CONF 2026

Containers, Azure Monitor, App Insights: o que tem a ver com I.A.?

Colocar I.A. em produção não é só conhecer LLM !



Márcio Rogério Nizzola

Principal Architect na CI&T

MVP CONF

Nossos Patrocinadores

2026

TD SYNNEX

UNIP
EDUCAÇÃO, POR SUA ESCOLHA

ACADI-TI Academia Inovadora de TI

CloudData

Advanced

clarus

DOT TECNOLOGIA

Ferragut

FunctionOne

Gertec

HIGH EXPERT EDUCAÇÃO E TECNOLOGIA

Innovent SOLUTIONS

MUNDO365

NEXTGENSKILLS

niteo Technologies

THOMPSON TECNOLOGIA

witec

power tuning performance em dados

MVP CONF

Meu agente funciona na minha máquina, mas quem coloca ele em produção?

Onde termina o Código e começa a arquitetura?

MVP Conf

MVP CONF

Márcio Rogério Nizzola

2026

- 5x MVP Microsoft - Developers Technologies
- Principal Architect na CI&T
- Professor na Etec de Itu
- Fundador do Meetup Itu Developers

Estudando programação a partir de 1989

Vivendo de software desde 1992

Principais tecnologias: C#, Python, IA, Javascript, Angular, React, Azure, Aws, Php, Vb



MVP Microsoft® Most Valuable Professional

www.linkedin.com/in/nizzola

www.nizzola.com.br

CI&T

ItuDevelopers®

www.mvpconf.com.br

O problema não é criar o agente...

Deployment e CI/CD

Build → Test → Deploy

Identidade e secrets

Microsoft Entra ID — Key Vault

Networking e segurança

VNets, Private Endpoints
Firewalls, NSGs, WAF

Scaling e disponibilidade

Auto Scaling
Alta Disponibiidade
Regiões, Failover

Observabilidade e troubleshooting

Azure Monitor
Application Insights
Logs, Métricas, Traces

Custos e governança

Custos
Tags e políticas
Compliance

Pronto! Meu agente funciona!

Meu Agente

```
var agent = new AI_Agent();
agent.AddTools();
agent.Run();
```

Funciona na minha máquina!

Quanto dessa infraestrutura o desenvolvedor realmente precisa saber montar e administrar?

AI
Agents
LLMs
Tools
MCP

BUILD
PROMPT
TEST
REPEAT

DEVELOPER ≠ OPS?

SÓ CÓDIGO NÃO BASTA...

IDEIA
CÓDIGO
TESTE
FUNCIONA!

MAIS ARQUITETURA MENOS CAFÉ?

TO DO?
- ☑ Container
- ☐ ACR
- ☑ Identity
- ☐ Networking
- ☐ Monitoring
- ☐ Scaling
- ☐ Budget
- ☐ Governance
- ... ???

Azure
Containers
DevOps
Security
Monitoring
Cost Management
Governance

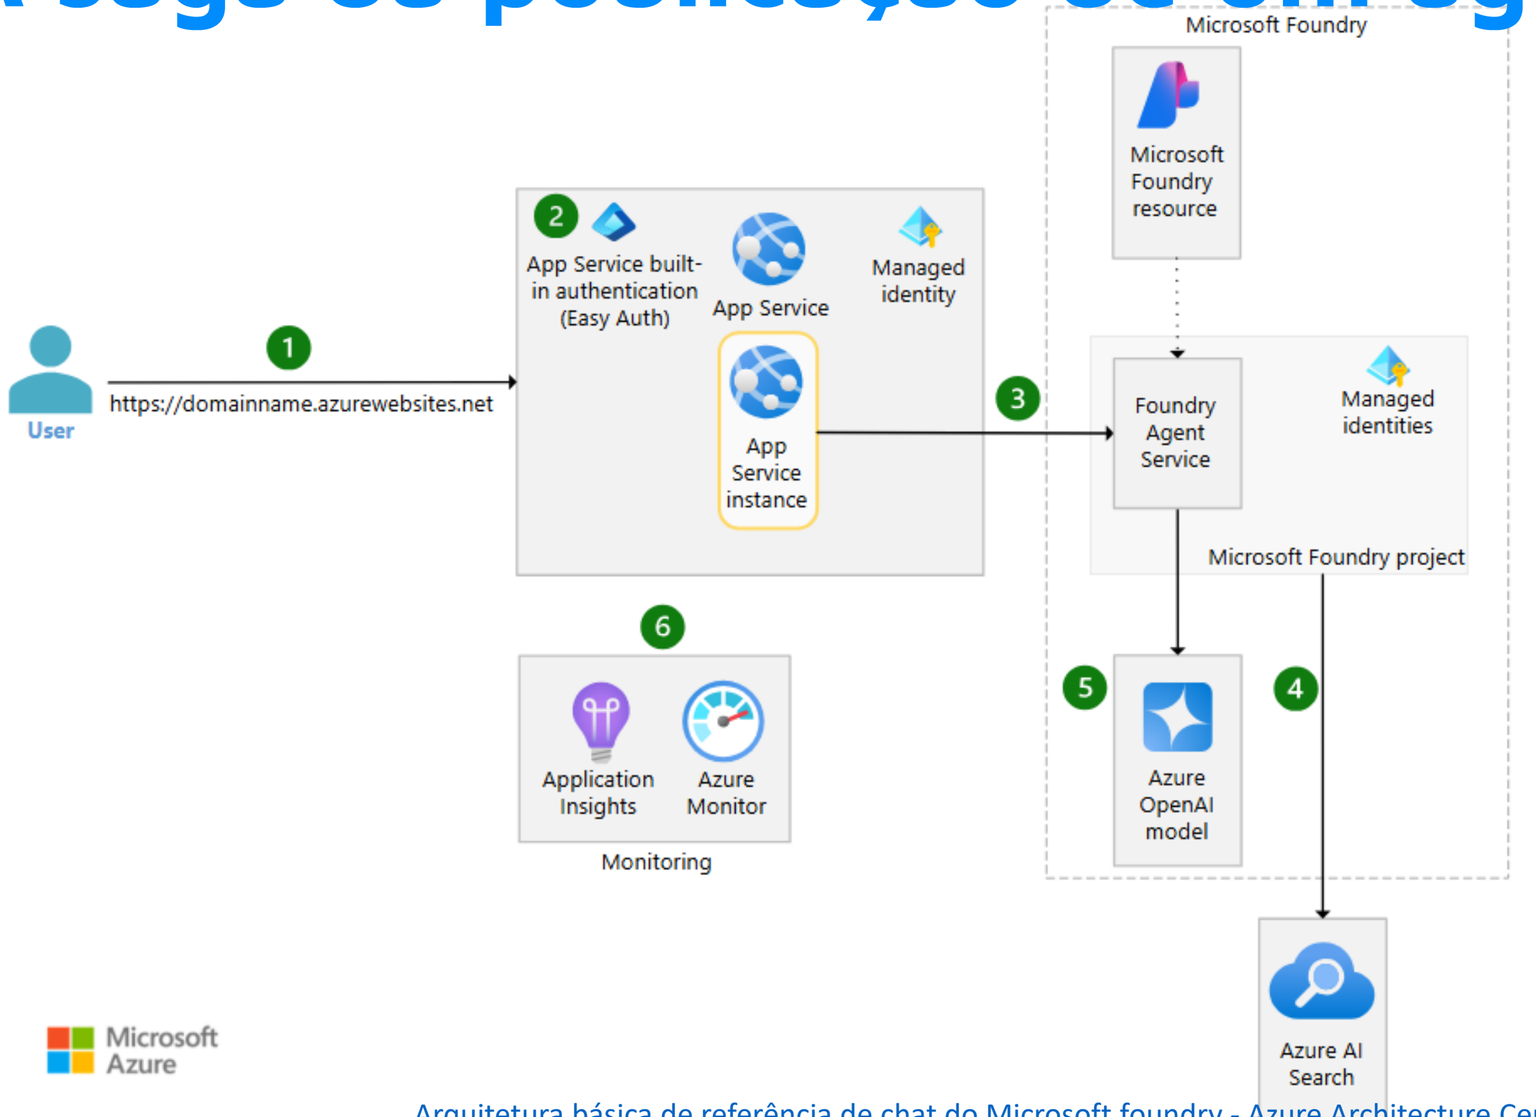
DO EXPERIMENTO À PRODUÇÃO EXISTE UMA JORNADA REAL.

MVP CONF 2026

MVP CONF

2026

A saga da publicação de um agente



Componentes da solução

- App Service
- Container Apps
- Foundry
- Foundry Agent Service
- Container Registry
- Azure Ai Search
- Managed Identities
- Applications Insights
- Azure Monitor

Faltou ainda:

- Azure Key Vault
- Banco de dados
- Storage
- Kubernetes
- Vnet
- Landing Zones

Microsoft Azure

[Arquitetura básica de referência de chat do Microsoft foundry - Azure Architecture Center | Microsoft Learn]

Preocupações em produção

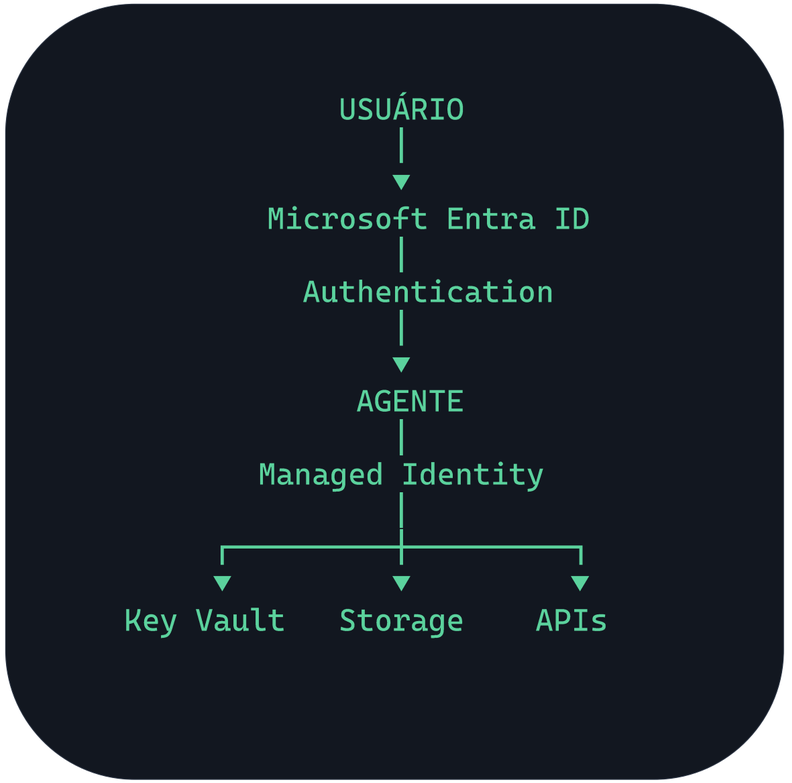
Identidade: quem é o usuário? Quem é o agente?
Um agente em produção precisa de identidade própria e de acesso controlado aos recursos.

👤 Identidade do usuário

- Microsoft Entra ID
- Autenticação e autorização
- RBAC / grupos / claims
- MFA e Conditional Access

🤖 Identidade do agente

- Managed Identity
- Permissões específicas
- Acesso a APIs, Storage, Key Vault, AI Services
- Princípio do menor privilégio

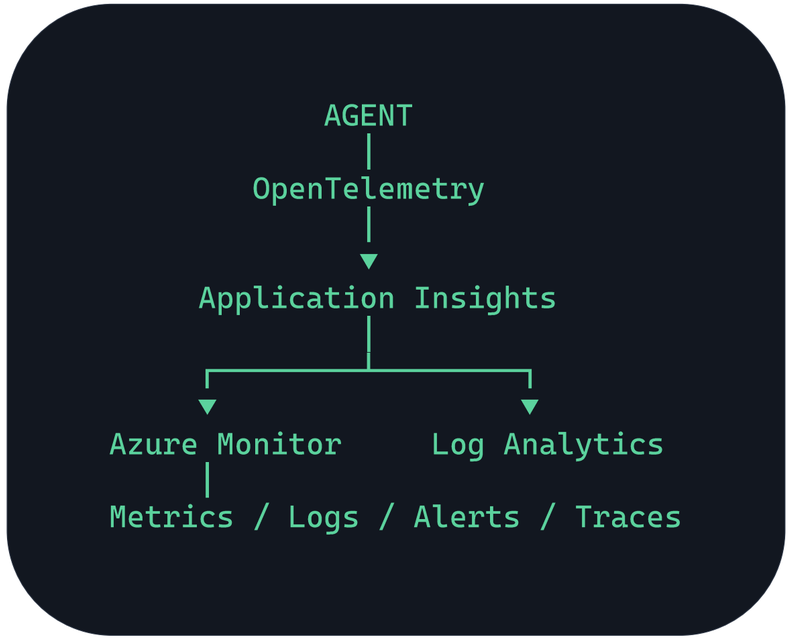


🔐 Infraestrutura de segurança

Microsoft Entra ID → identidade e autorização
Managed Identity → identidade do agente
Azure Key Vault → secrets e certificados
RBAC → controle de acesso aos recursos
Private Endpoints / VNet → isolamento de rede
Azure Monitor + App Insights → auditoria e observabilidade

Preocupações em produção

Observabilidade ➔
Azure Monitor + Application Insights



O que responde

- Qual modelo foi chamado?
- Quantos tokens foram utilizados?
- Quais tools foram executadas?
- Quanto tempo levou cada etapa?
- Qual contexto e qual sessão originaram o problema?
- Qual dependência falhou?

Quando colocar em produção a maioria dos clientes vão querer respostas para estas perguntas

Hosting: onde o agente vai rodar?

A primeira decisão: qual runtime atende o workload?

Azure Web App
Quando?

- API ou aplicação web relativamente simples
- Deployment rápido
- Menor complexidade operacional
- Pode hospedar aplicações containerizadas

Azure Container Apps
Quando?

- Aplicações containerizadas
- Microservices e workloads event-driven
- Autoscaling
- Menor preocupação com infraestrutura

Azure Kubernetes Service — AKS
Quando?

- Necessidade de controle avançado
- Muitos serviços e workloads
- Networking e scheduling complexos
- Requisitos específicos de plataforma
- Equipe preparada para operar Kubernetes

Hosted Agent
Quando?

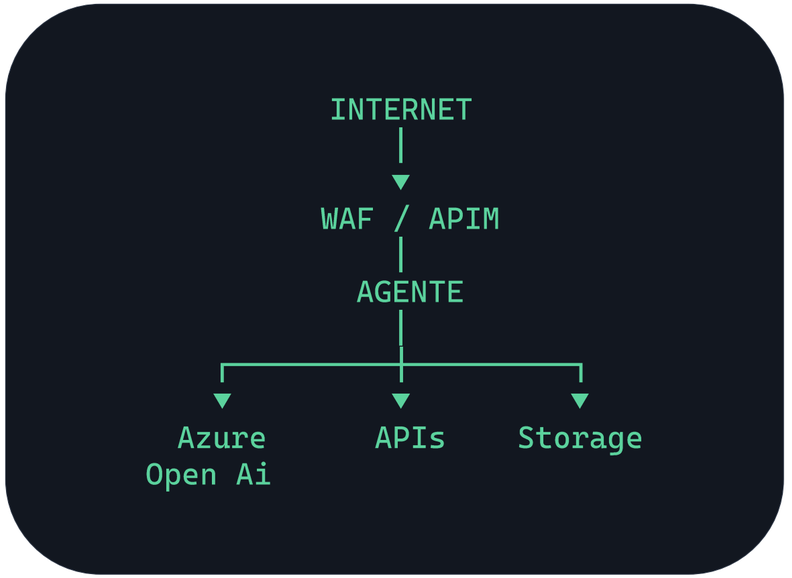
- O workload se encaixa no modelo de agentes gerenciados
- Queremos reduzir a infraestrutura operacional
- Integração com Microsoft Foundry / Agent Framework

A pergunta não é "qual serviço é melhor?"
A pergunta é: quanto controle e quanto gerenciamento meu workload realmente exige?

Networking: como o agente conversa com o mundo?

Precisamos pensar em:

- VNet / Subnets
- Private Endpoints
- NSG / Firewall
- Ingress e Egress
- DNS
- API Management
- WAF
- Controle de tráfego
- Comunicação com serviços internos



“Quem pode conversar com quem?”

Dados: onde estão o contexto e a memória?

O agente precisa acessar dados

Podem existir:

- SQL Database
- Cosmos DB
- Azure Storage
- Blob Storage
- Azure AI Search
- Redis
- bancos corporativos
- APIs internas
- Azure Service Bus

Perguntas importantes

- Que dados o agente pode acessar?
- Em nome de quem?
- Como os dados são filtrados?
- Existe isolamento por usuário/tenant?
- O agente pode recuperar informações que o usuário não poderia acessar?



Secrets e configuração: onde ficarão as credenciais do agente

NUNCA
Código → API KEY → Github

PREFIRA
Managed Identity → Key Vault → Secrets / keys → Agent

Precisamos proteger:

- API Keys
- Connection Strings
- Tokens
- Certificados
- Secrets
- Configurações sensíveis

Se o segredo está no código, ele já não é mais segredo.

Segurança da aplicação de IA

Ameaças da era agêntica :

- **Prompt Injection**

"Ignore suas instruções e faça outra coisa."

- **Excessive Agency**

O agente possui permissões demais.

- **Data Exfiltration**

O agente acessa e retorna dados que não deveria.

- **Tool Abuse**

Uma ferramenta legítima é utilizada de forma indevida.

- **Insecure Output**

A saída do modelo é utilizada diretamente por outro sistema sem validação.

O agente também ainda pode ser atacado na infraestrutura tradicional:

- Authentication
- Authorization
- Network Security
- Secrets
- Vulnerability Management



Custos e governança

“Funciona” não significa “é sustentável”.
Um agente pode consumir:

- tokens;
- modelos;
- compute;
- storage;
- banco de dados;
- AI Search;
- observabilidade;
- networking;
- APIs externas.

Precisamos saber:

- Quanto custa uma execução?
- Qual modelo está sendo utilizado?
- Quantos tokens são consumidos?
- Quais tools são mais caras?
- Quem pode criar agentes?
- Quem pode publicar?
- Quem pode acessar os dados?
- **Quais são os agentes existentes na organização**



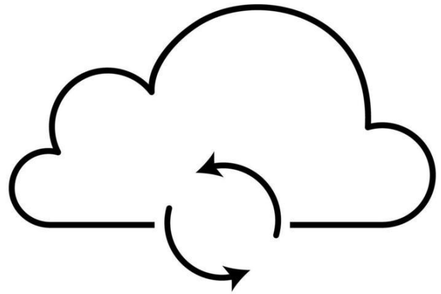
Observabilidade mostra o que aconteceu.
Governança ajuda a controlar o que pode acontecer.

Disaster Recovery e continuidade

E se o agente cair?

Precisamos pensar em:

- Backup
- Recovery
- Multi-region, quando necessário
- RTO (**quanto tempo um sistema pode ficar parado)**
- RPO (**define quanto dado pode ser perdido sem causar prejuízos significativos.)**
- Failover
- Estado das sessões
- Disponibilidade dos dados
- Disponibilidade dos modelos e dependências



Um agente em produção precisa responder a 8 grandes perguntas

*"Não é apenas fazer funcionar.
É fazer funcionar de forma segura,
escalável, observável e sustentável."*

1. Quem é o usuário?
Como ele acessa?
E quais são suas permissões?

Usuário
(Microsoft Entra ID)

2. Onde ele roda?
Qual serviço de hosting usar?

Azure Web App · Container Apps · AKS · Hosted Agent

3. Com quem ele conversa?
Como é feita a comunicação de forma segura?

Networking (VNet, Firewall) → API Management WAF

4. O que ele pode acessar?
Como protegemos credenciais e dados?

Key Vault (Secrets) · Storage e Bancos · Azure AI Search (RAG)

5. Como ele é publicado?
Como uma nova versão chega à produção?

Código → CI/CD → Testes → Registry → Deploy

6. Como ele escala?
O que acontece quando o uso cresce?

Auto Scaling · Alta Disponibilidade · Performance

7. Como sabemos o que aconteceu?
Como monitorar e diagnosticar problemas?

Azure Monitor · Application Insights · Logs, Métricas e Traces

8. Quanto custa e quem controla?
Como garantir o uso sustentável?

Custos · Orçamentos · Políticas · Governança

Olá!
Pode me ajudar?

AI

Agente de IA

Dados Corporativos

Documentos · Bancos de Dados · APIs · Sistemas Internos

IDEIA
CÓDIGO
TESTES
DEPLOY
PRODUÇÃO

VALOR
PARA O NEGÓCIO

FROM PROMPT TO PRODUCTION

Funciona na minha máquina...
E agora? 🤔

Pronto para a produção real?

Da experimentação à solução de impacto.

PESSOAS
PLATAFORMA
PROCESSOS
GOVERNANÇA
RESULTADOS

Será que o desenvolvedor precisa montar e administrar tudo isso?

Até aqui...

Nós vimos que colocar um agente em produção envolve:

Hosting
Identity
Networking
Secrets
Data
CI/CD
Scaling
Security
Observability
Governance
Cost
Resilience

E se a plataforma assumisse parte dessa complexidade?



Azure Hosted Agents

A infraestrutura continua existindo.
Mas parte dela vira plataforma.

Hosted Agents unem código próprio e plataforma gerenciada



02 / O CONCEITO

Seu agente é código.

O runtime é gerenciado.

PROMPT-BASED →

Definido por prompts e ferramentas no portal do Foundry.

HOSTED →

Seu código empacotado como imagem de contêiner no Agent Service.

DIVISÃO →

Modelos fazem o raciocínio; seu código controla a orquestração.

Princípio: a plataforma gerencia o ciclo de vida conforme a atividade.

Escolha Hosted Agents quando o agente exige runtime próprio

03 / QUANDO USAR

A decisão nasce das necessidades do código, do contrato e do estado.

01 Bring your own code

Use Agent Framework, LangGraph, Semantic Kernel ou código customizado.

02 Protocolos personalizados

Aceite webhooks e payloads próprios com o protocolo Invocations.

03 Controle de recursos

Defina CPU e memória para a sandbox do agente.

04 Workloads com estado

Persista arquivos e estado entre turnos usando $HOME e /files.

Regra prática: se seu agente faz mais que um agente criado no Playground, considere Hosted Agents.

MVP CONF

2026

A fronteira de responsabilidade fica explícita

05 / ARQUITETURA OPERACIONAL

Delegar o runtime não significa delegar o comportamento do agente.

VOCÊ POSSUI

Código e imagem do agente
O que roda dentro do sandbox

Orquestração, prompts e ferramentas
Decisões do fluxo de execução

Contratos e regras de negócio
Semântica da aplicação

Testes e mitigação responsável
Qualidade, segurança e confiabilidade

A PLATAFORMA POSSUI

Endpoint dedicado
Roteamento e acesso programático

Identidade do agente
Entra ID criado no deployment

Provisionamento por sessão
Computação sob demanda e isolamento

Estado e observabilidade
Persistência, Application Insights e OpenTelemetry

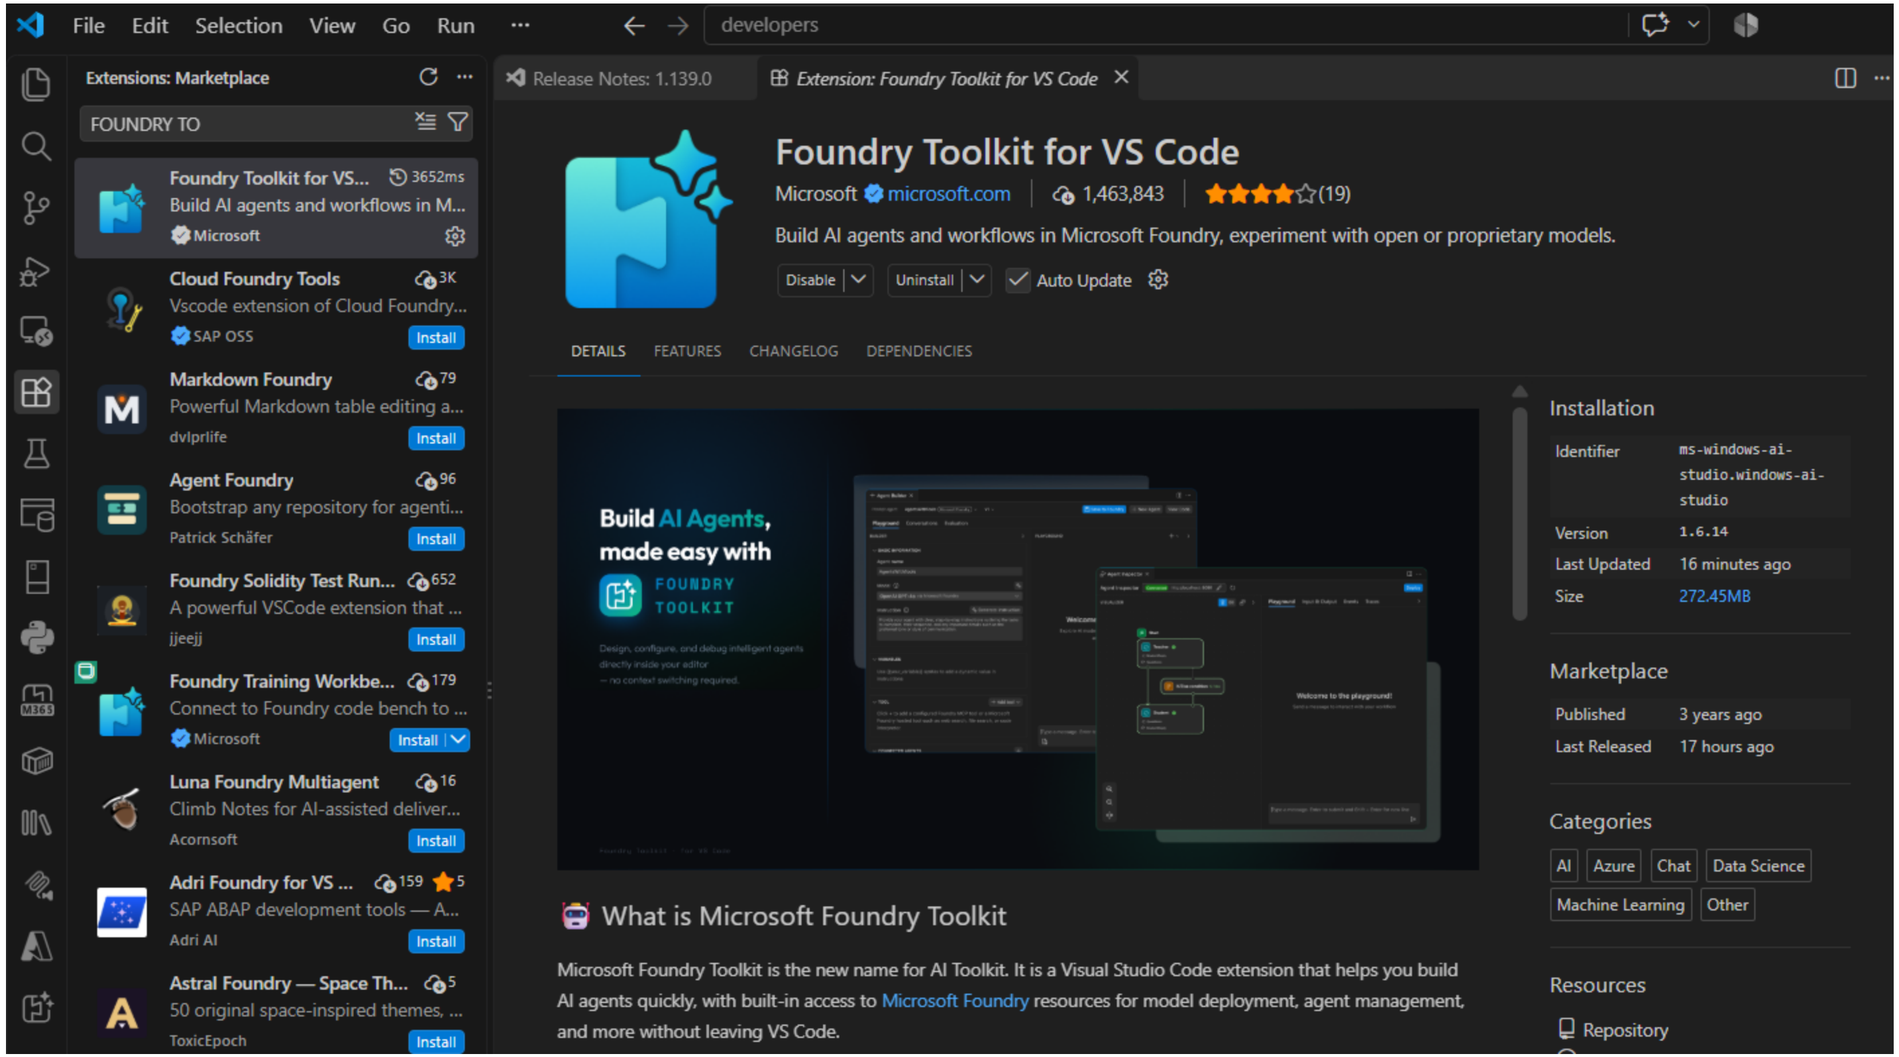
Regra prática: a plataforma opera o envelope; o time responde pelo agente.

MVP CONF

2026

Rodei na minha máquina e agora, onde eu publico esse agente?

Azure AI Foundry



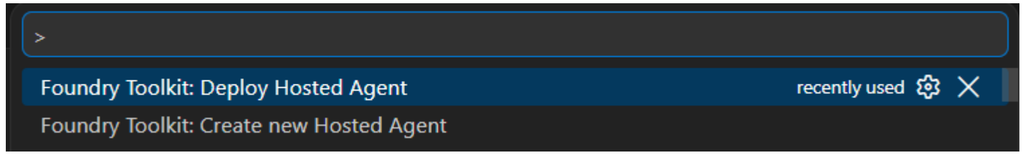
MVP CONF

2026

Você tem 3 passos dentro do VSCODE para criar um agente

Passo 1

CTRL + Shift + P – abra a paleta de comandos e encontre “Foundry Toolkit: Create new Hosted Agent

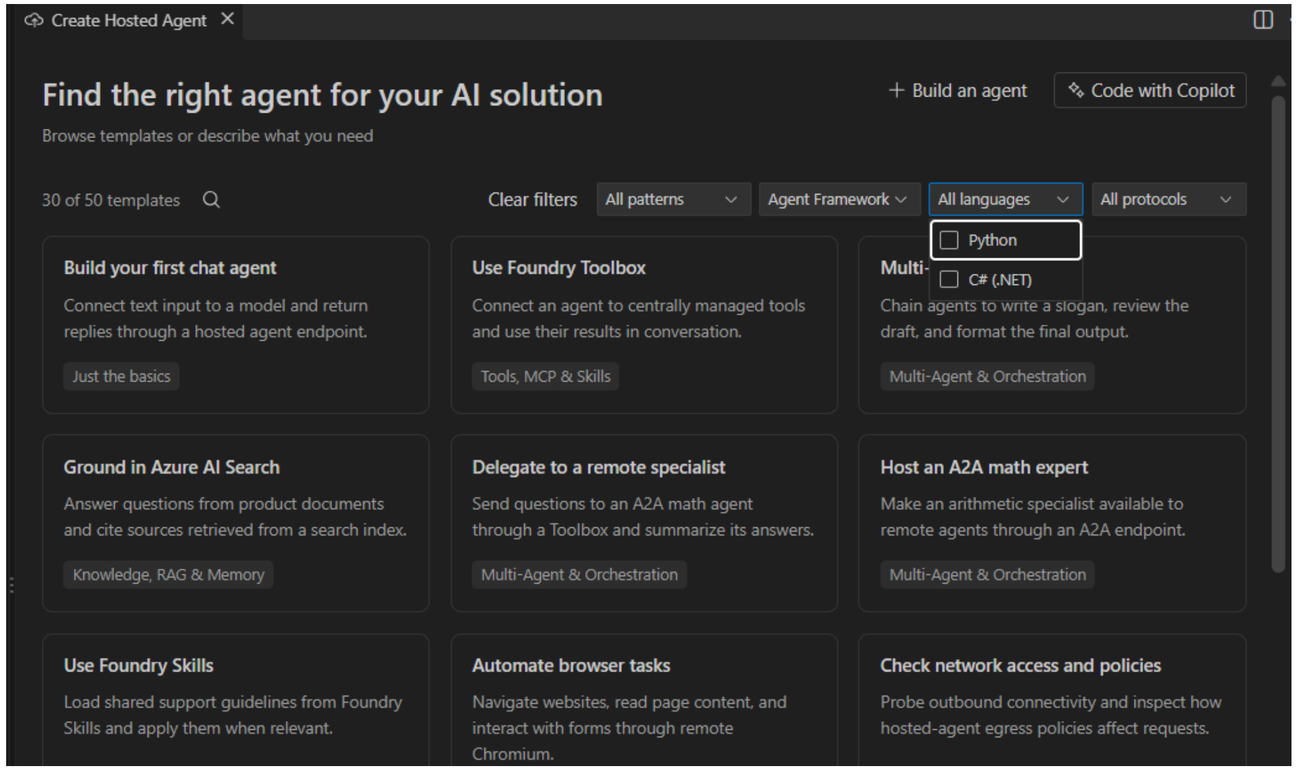


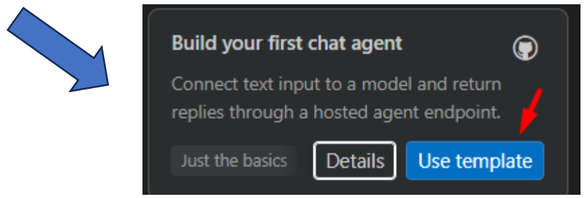
Passo 2

Selecione:

- Linguagem
- Framework
- Protocolo

E depois procure um template de agente para a solução do seu problema





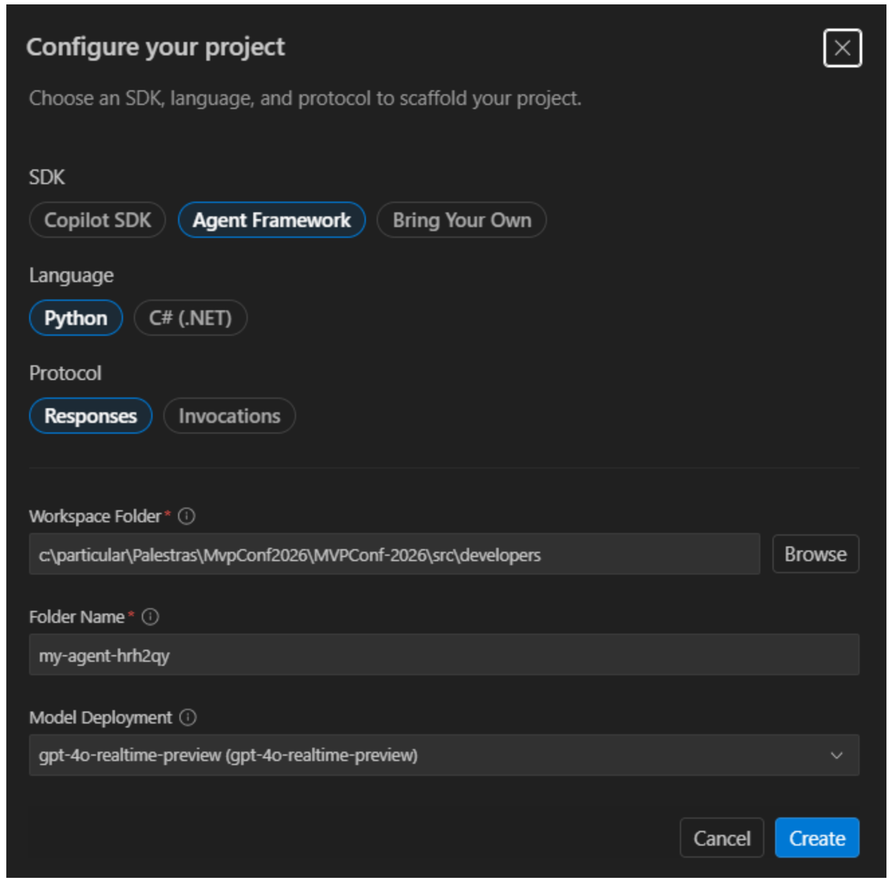
MVP CONF

2026

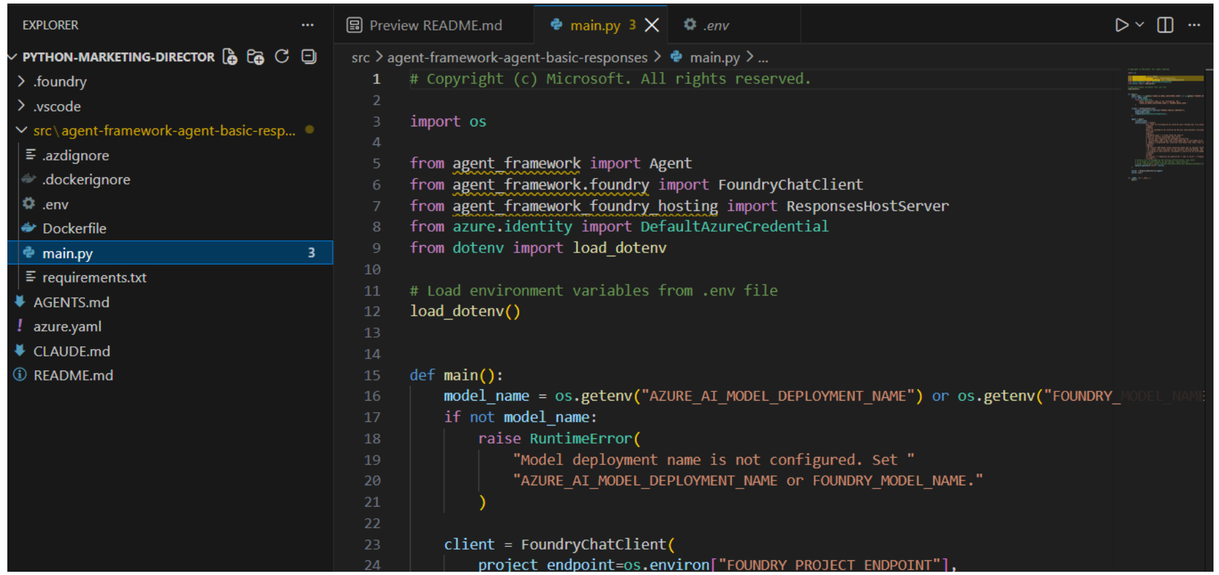
Você tem 3 passos dentro do VSCODE para criar um agente

Passo 3

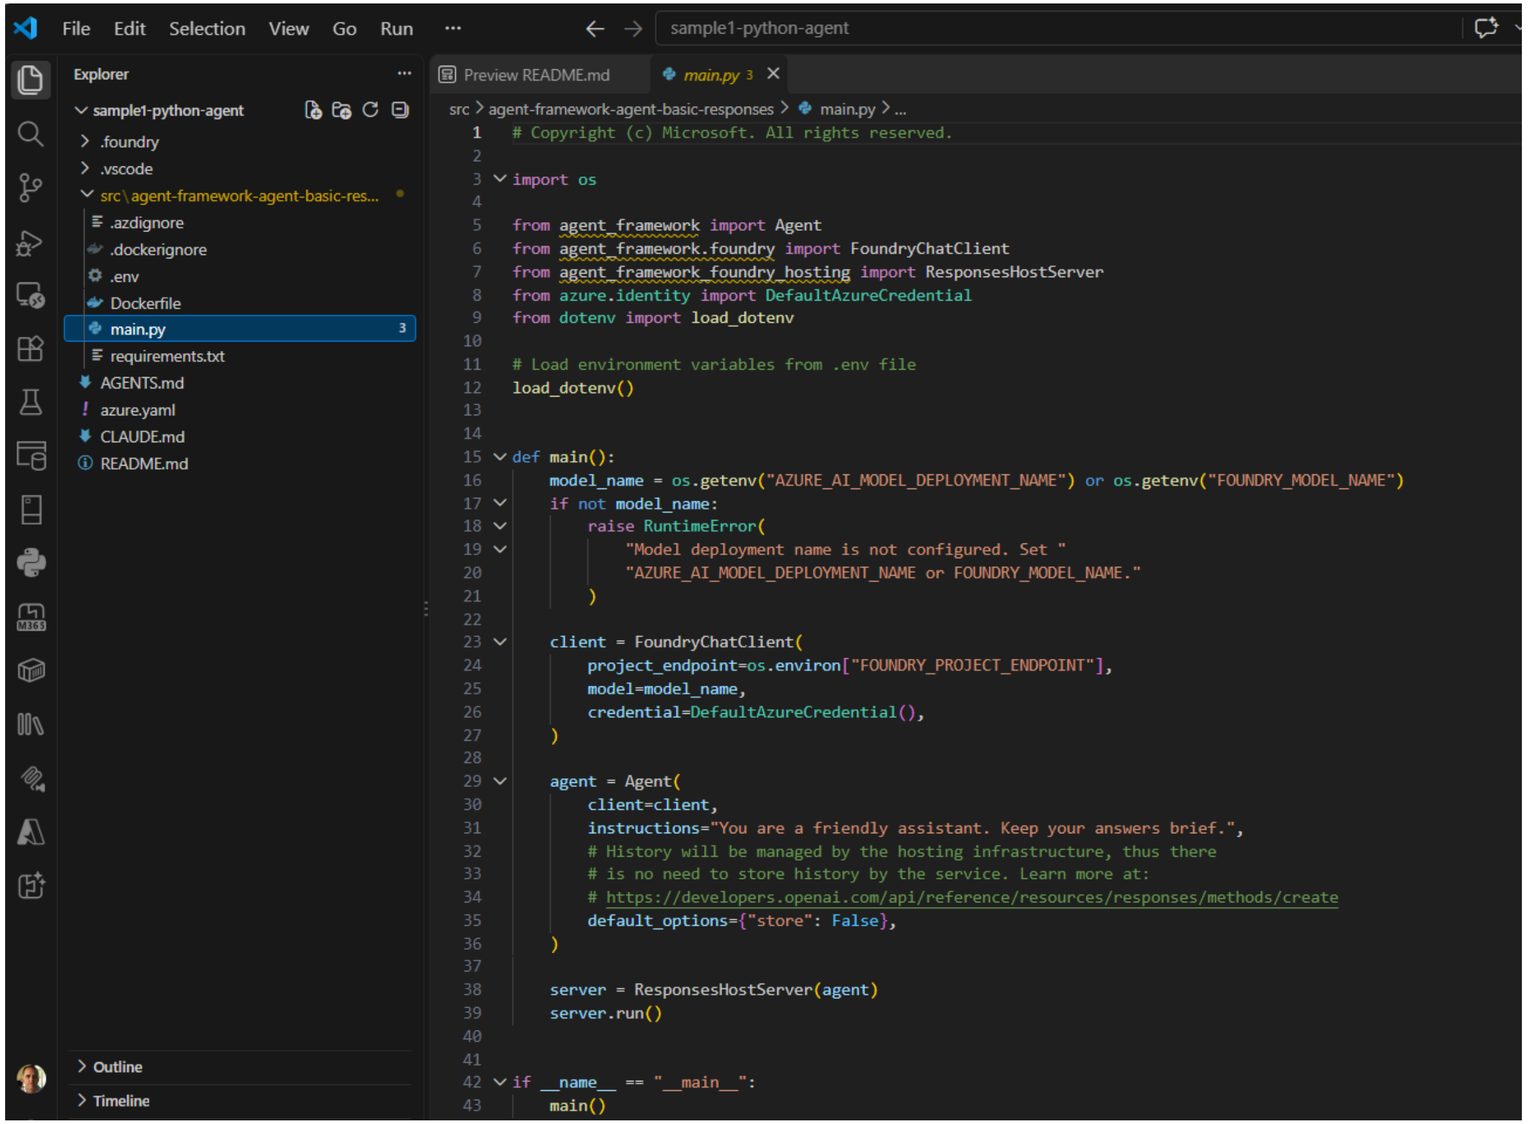
Configure pasta, nome e modelo



Pronto agora existe um código base para montar seu agente



Pronto, projeto base criado



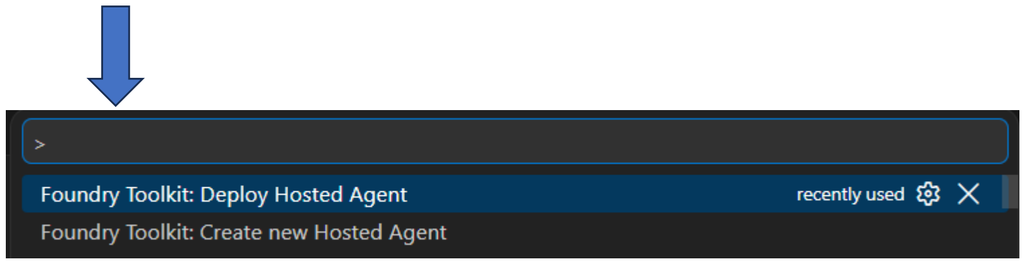
MVP CONF

2026

Você tem que publicar o agente

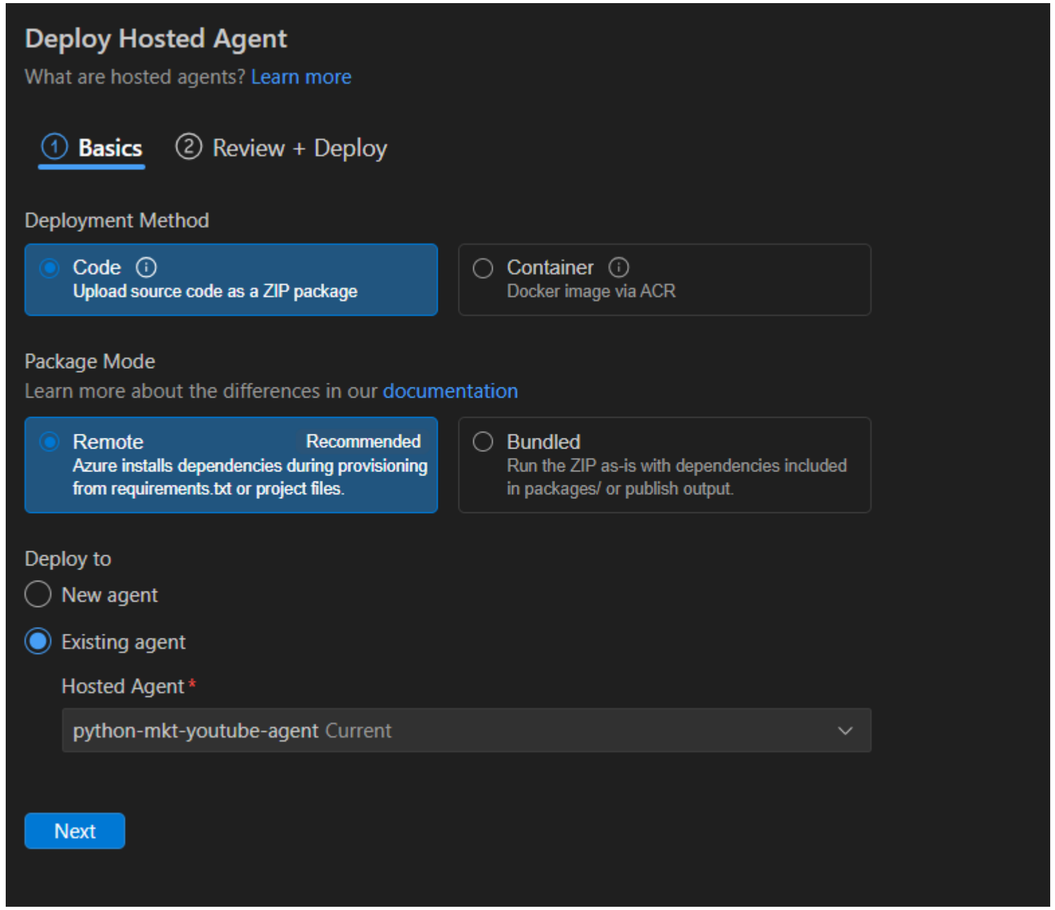
Passo 1

CTRL + Shift + P – abra a paleta de comandos e encontre “Foundry Toolkit: Deploy Hosted Agent



Passo 2

Selecione as suas preferências



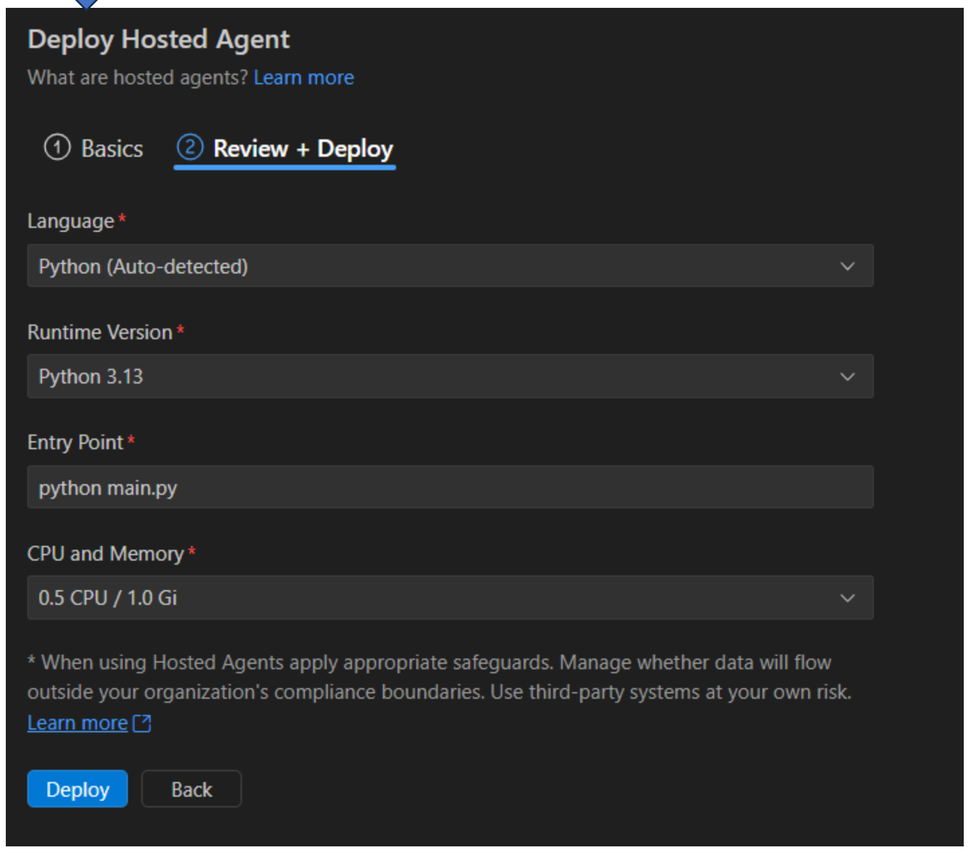
MVP CONF

2026

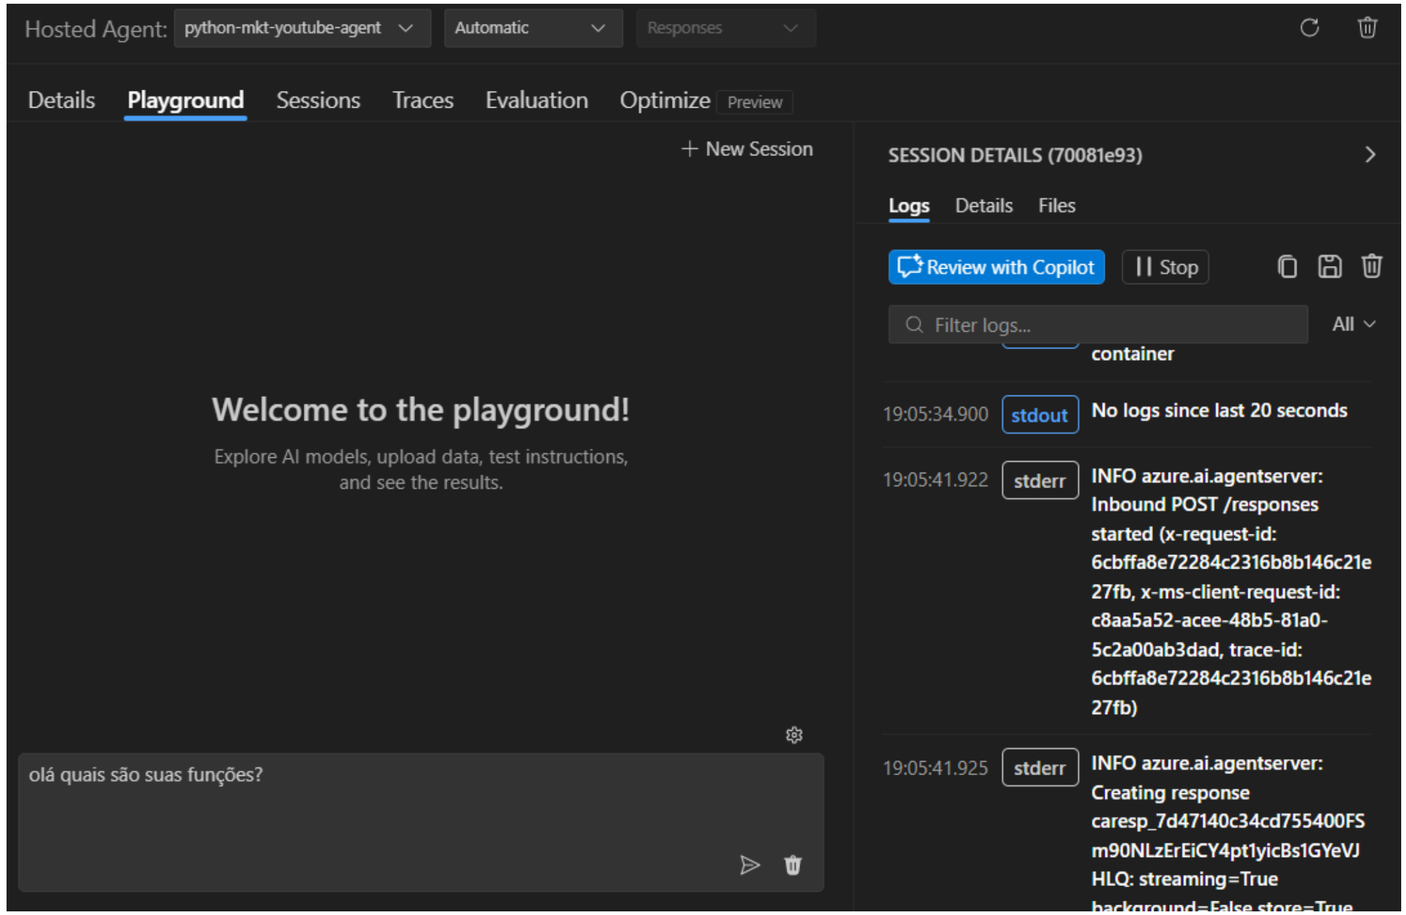
Você tem que publicar o agente

Passo 3

Verifique as informações ou altere-as e clique “Deploy”



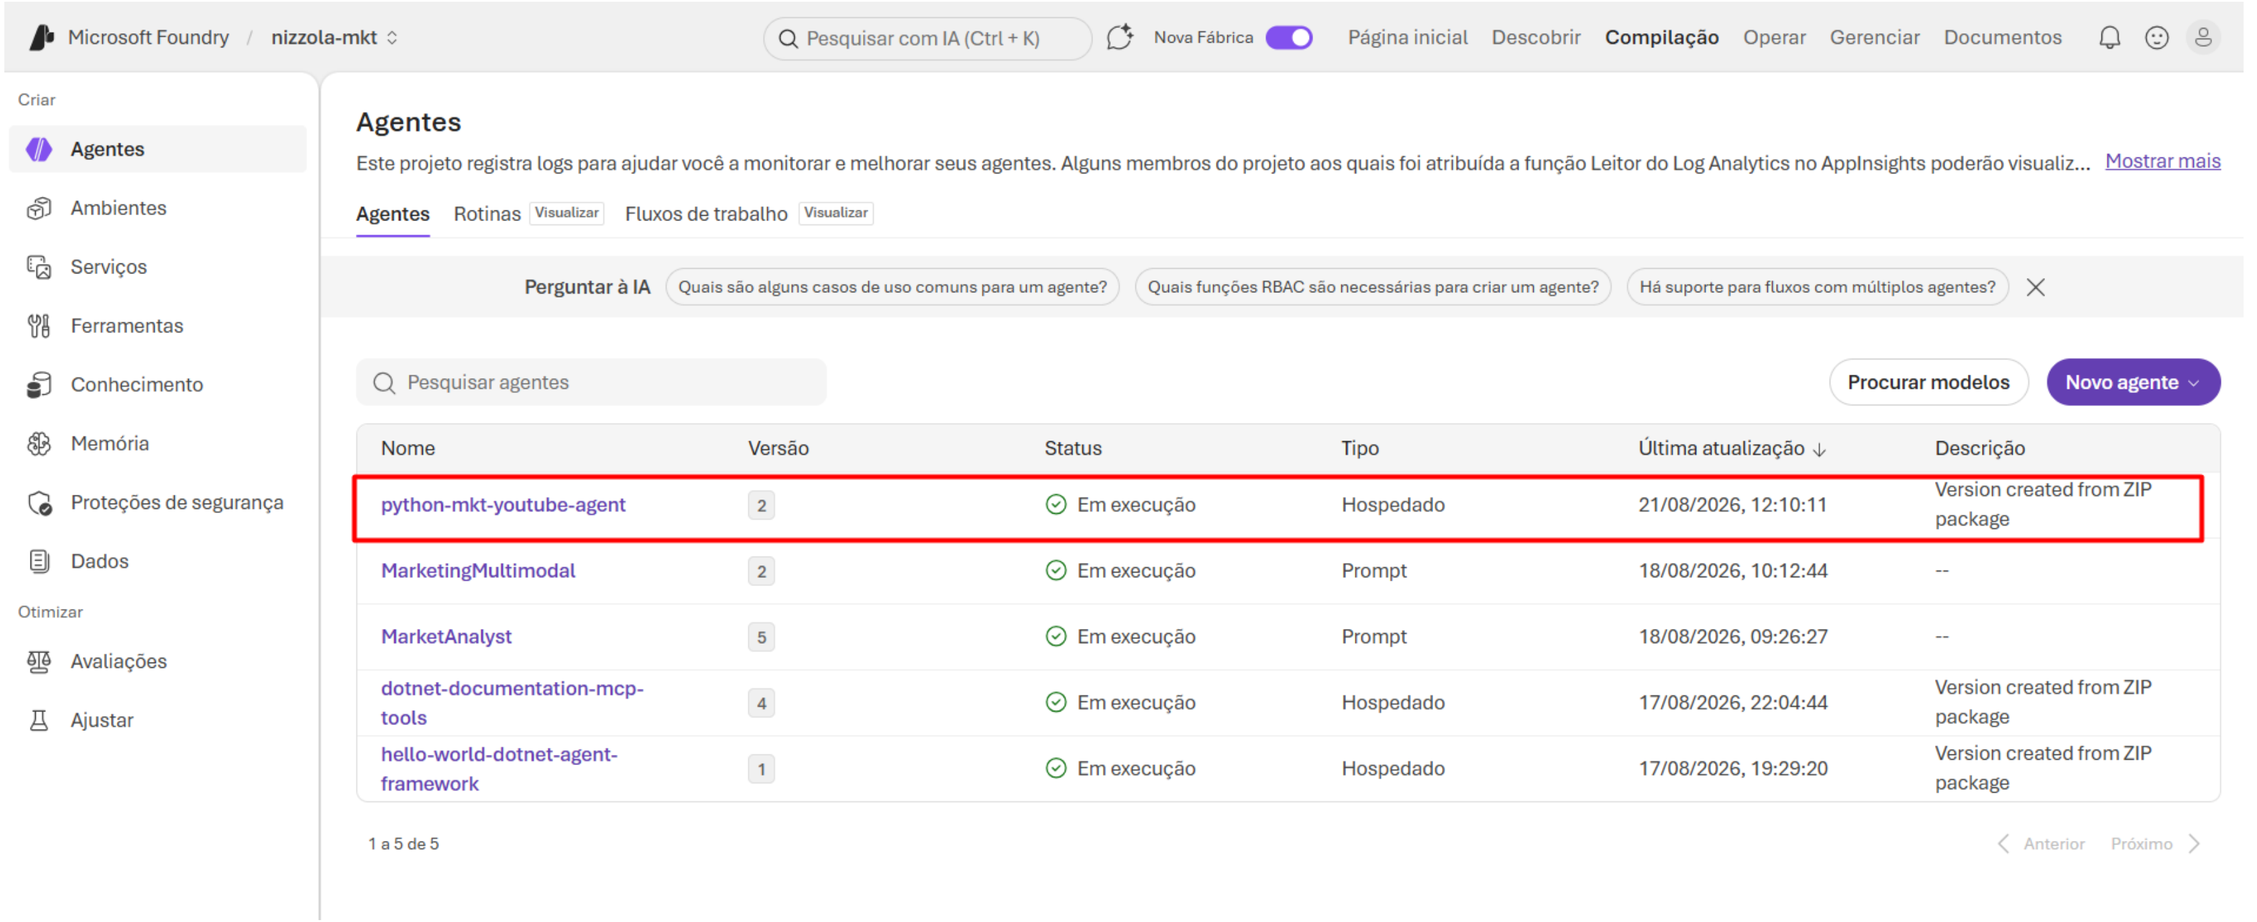
Se tudo der certo, será aberto o playground para testar



MVP CONF

2026

E seu agente estará disponível dentro do Foundry



Hosted Agent x Self-hosted

Self-hosted

- Mais controle
- Mais responsabilidade operacional
- Maior liberdade de recursos
- Networking mais configurável

Hosted Agent

- Mais abstração
- Menos operação direta
- Recursos mais controlados
- Experiência especializada para agentes
- Evaluation

Hosted agente - Preços

Region: Brazil South

Currency: Brazil – Real (R$) BRL

1 USD = 5.1701 BRL

Hosted agents	vCPU (hour): **R$0.6167** Memory (GiB-hour): **R$0.0733**
Models	See Foundry Models pricing page for consuming model tokens.
Tools and Knowledge	**Built-in Tools:** File Search Storage: **R$0.6825**/GB of vector-storage per day (1 GB free) Code Interpreter: **R$0.2048**/session Web Search: **R$72.3814**/1,000 transactions Custom Search: **R$72.3814**/1,000 transactions You will incur separate charges and licenses for tools and knowledge connections, including Azure Logic Apps connectors, Microsoft Fabric data agent, Microsoft SharePoint, Grounding with Bing Search, Foundry IQ (by Azure AI Search), and your own licensed data. For ready-to-use APIs like Speech, Language, and Translator that can be invoked by your agents, learn more at the Foundry Tools pricing page

Foundry Agent Service - Pricing | Microsoft Azure

Microsoft

Qual plataforma de Agentes de IA escolher?

Da ideia ao impacto, com a plataforma certa para o seu cenário.

Agentes hoje.
Mais possibilidades amanhã.



Pessoas
Processos
Agentes
Resultados

Qual é o seu cenário principal para o agente de IA?

Preciso de uma solução rápida, com baixa necessidade de código e integrada ao ecossistema Microsoft?

Não

Preciso de orquestrações complexas, fluxos de vários agentes ou lógica personalizada?

Não

Preciso de controle total da execução do modelo, ambiente privado ou requisitos de conformidade muito rígidos?

Sim

Sim

Sim

Microsoft Copilot Studio

Código baixo / SaaS

Implantação rápida de agentes para o seu negócio

Melhor para:

- Implantação rápida
- Integração direta com aplicativos Dynamics 365
- Personalização orientada por analistas de negócios
- Agentes de recuperação e tarefas

Dynamics 365

Microsoft 365

Power Platform

Fornece:

- Conectores predefinidos
- Integração do Pesquisa de IA do Azure
- Recursos internos de IA responsável

Ideal para começar rápido e gerar valor

Microsoft Foundry

Pro-code / PaaS

Construa e orquestre agentes com flexibilidade e escala

Melhor para:

- Orquestrações complexas e fluxos de trabalho de vários agentes
- Lógica personalizada, comportamento generativo avançado
- Integração com sistemas empresariais em escala

Azure OpenAI

Azure AI Foundry

GitHub

A Foundry fornece:

- Modelos de agente declarativos ou que priorizam o código
- Ambiente de execução hospedado
- Catálogo de modelos com opções OpenAI, Antropic, Meta e Mistral
- Suporte para o Protocolo de Atividade e interações de agente para agente

Escolha quando precisar de flexibilidade e escala

GPUs e contêineres

Código profissional / IaaS

Controle total para cenários críticos e especializados

Use quando:

- Você precisa de controle total da execução do modelo
- Os agentes precisam operar em um ambiente de computação privado e isolado
- Ambientes de conformidade estritos exigem hospedagem de modelo BYO

Azure Kubernetes Skrvice (AKS)

Azure VMs com GPUs

Azure Container Registry

Possibilita:

- Execução de modelos personalizados (BYO)
- Infraestrutura isolada e segura
- Atendimento a requisitos regulatórios e de conformidade
- Total liberdade de configuração e otimização

Escolha quando o controle e a conformidade são prioridade

Para encerrar

Comparar simplesmente o preço de uma instância com outra, posso estar fazendo uma comparação errada.

Porque na infraestrutura tradicional eu também tenho custo de ACR, networking, monitoramento, configuração, manutenção, atualização, troubleshooting e principalmente **tempo das pessoas**.



Infraestrutura também tem custo de complexidade.

Se meu projeto precisa de GPU, muito mais memória, controle avançado de rede, requisitos específicos de segurança ou um runtime altamente customizado, talvez a abstração do Hosted Agent não seja adequada.

Não é escolher um ou outro, é decisão arquitetural !

Referências e Recursos Adicionais

Documentação Oficial do Microsoft Agent Framework

learn.microsoft.com/en-us/agent-framework/

Repositório de Exemplos (Agent Framework Samples)

github.com/microsoft/Agent-Framework-Samples
github.com/microsoft/agent-framework/tree/main/dotnet/samples

Blog de Engenharia da Microsoft (Azure AI)

devblogs.microsoft.com/agent-framework/

Hosted Agents

modelcontextprotocol.io

Contatos

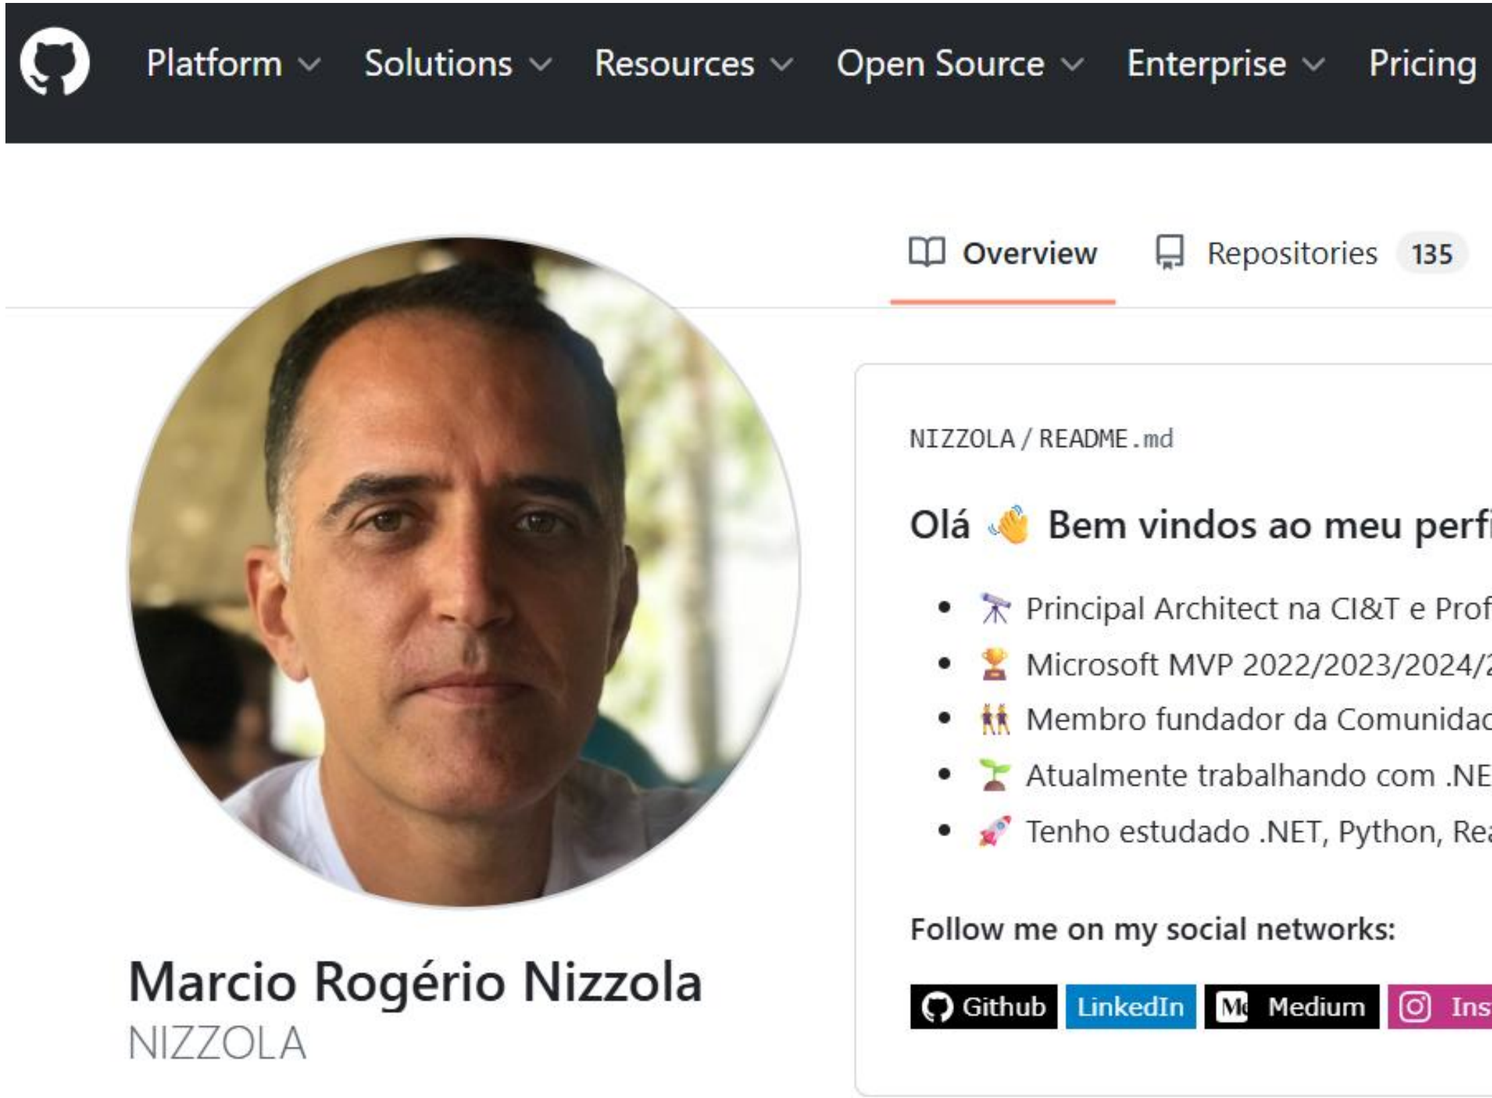
https://linktr.ee/NIZZOLA

https://github.com/nizzola

https://www.linkedin.com/in/nizzola

Mais de 120 artigos sobre .NET

marcionizzola.medium.com



Em breve

Um canal com dicas rápidas de programação, com vídeos de até 8 minutos !



https://www.youtube.com/@codein8

MVP CONF

2026

Siga MVP Conf nas redes sociais

LINKEDIN

@MVPCONF

MVP CONF

2026

Obrigada(o)!

Coloque aqui seus dados de contato